

图像压缩中的线性代数方法研究

2025082001013 刘泰宏, 2025082001012 刘林皓, 2025082001007 况光奇

摘要: 本文从线性代数角度探讨图像压缩, 系统阐述了快速傅里叶变换 (FFT) 的矩阵分解与基于主成分分析 (PCA) 的低秩近似的原理, 并在 Kodak 数据集上验证了两种算法的重建质量与压缩率。

关键词: 图像压缩; 线性代数; FFT; SVD; 低秩近似

1 引言

随着图像与多媒体数据量快速增长, 如何在保证视觉质量的前提下降低存储与传输成本成为关键问题。许多图像压缩方法的数学内核可以归结为线性变换与矩阵分解: 通过基变换将信号表达在频域或其他基下以实现能量聚集, 或通过低秩分解提取主要成分以实现有效近似。

本文从线性代数角度研究图像压缩, 聚焦两类典型方法: 基于快速傅里叶变换 (FFT) 的频域截断, 以及基于奇异值分解 (SVD/PCA) 的低秩近似。我们分别给出 DFT/FFT 的矩阵表示与分治分解解释, 以及利用截断 SVD 的最优低秩近似性质说明 PCA 压缩的理论依据。随后在 Kodak 数据集上比较不同保留比例/秩下的 PSNR、SSIM 与压缩率 (CR), 并讨论浮点载荷存储可能导致的“负压缩”等工程现象。

2 快速傅里叶变换 (FFT)

快速傅里叶变换 (Fast Fourier Transform, FFT) 是离散傅里叶变换 (Discrete Fourier Transform, DFT) 的一种高效计算方法。尽管 FFT 常被视为算法层面的优化, 但从线性代数的角度来看, 其本质是对离散傅里叶线性变换所对应矩阵结构的分解与重排。这一思想在图像压缩等应用中具有重要的理论意义。

2.1 傅立叶变换

傅里叶变换 (Fourier Transform, FT) 是一种分析信号的方法, 它可以分析信号的成分, 也可反过来用这些成分合成信号。通过使用天然具有正交性的三角函数 ($\sin$ 、 $\cos$) 作为信号的成分, 借助幅角的形式表示频率和相位, 傅立叶变换实现了信号从时域到频域的变换。

设 $f(t)$ 是关于时间 t 的函数, 则傅立叶变换可以检测频率 ω 的周期在 $f(t)$ 出现的程度:

$$F(\omega) = \mathbb{F}[f(t)] = \int_{-\infty}^{\infty} f(t)e^{-i\omega t} dt \quad (1)$$

它的逆变换是

$$f(t) = \mathbb{F}^{-1}[F(\omega)] = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega) e^{i\omega t} d\omega \quad (2)$$

逆变换的形式与正变换非常类似，分母 2π 恰好是指数函数的周期。

傅里叶变换相当于将时域的函数与周期为 2π 的复指数函数进行连续的内积。逆变换仍旧为一个内积。

2.2 离散傅里叶变换

离散傅里叶变换 (Discrete Fourier transform, DFT) 是傅里叶变换在时域和频域上都呈离散的形式，将信号的时域采样变换为其 DTFT (discrete-time Fourier transform) 的频域采样。

相应地，我们可以将 FT 积分形式的连续的函数内积改写成 DFT 求和形式的内积。

设 $\{x_n\}_{n=0}^{N-1}$ 是某一满足有限性条件的序列，它的离散傅里叶变换 (DFT) 为：

$$X_k = \sum_{n=0}^{N-1} x_n e^{-i\frac{2\pi}{N}kn} \quad (3)$$

通常以符号 $\mathcal{F}$ 表示这一变换，即

$$\hat{x} = \mathcal{F}x \quad (4)$$

类似于积分形式，它的逆离散傅里叶变换 (IDFT) 为：

$$x_n = \frac{1}{N} \sum_{k=0}^{N-1} X_k e^{i\frac{2\pi}{N}kn} \quad (5)$$

可以记为：

$$x = \mathcal{F}^{-1}\hat{x} \quad (6)$$

实际上，DFT 和 IDFT 变换式前面的归一化系数并不重要。在上面的定义中，DFT 和 IDFT 前的系数分别为 1 和 $\frac{1}{N}$ 。有时我们会将这两个系数都改 $\frac{1}{\sqrt{N}}$ 。

离散傅里叶变换仍旧是时域到频域的变换。由于求和形式的特殊性，可以有其他的解释方法。如果把序列 x_n 看作多项式 $f(x)$ 的 x^n 项系数，则计算得到的 X_k 恰好是多项式 $f(x)$ 代入单位根 $e^{-\frac{2\pi i k}{N}}$ 的点值 $f(e^{-\frac{2\pi i k}{N}})$ 。这便构成了卷积定理的另一种解释办法，即对多项式进行特殊的求值操作。离散傅里叶变换恰好是多项式在单位根处进行求值。

2.3 矩阵表示

由于离散傅立叶变换是一个线性算子，所以它可以用矩阵乘法来描述。在矩阵表示法中，离散傅立叶变换表示如下：

$$\begin{bmatrix} X_0 \\ X_1 \\ X_2 \\ \vdots \\ X_{N-1} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & \omega & \omega^2 & \cdots & \omega^{N-1} \\ 1 & \omega^2 & \omega^4 & \cdots & \omega^{2(N-1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \omega^{N-1} & \omega^{2(N-1)} & \cdots & \omega^{(N-1)(N-1)} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_{N-1} \end{bmatrix} \quad (7)$$

其中 $\omega = e^{-i\frac{2\pi}{N}}$ 表示 N 次单位根。

设一维离散信号（或图像的一行像素）表示为向量：

$$\mathbf{x} = (x_0, x_1, \dots, x_{N-1})^T \in \mathbb{C}^N.$$

变换后频域强度表示为向量：

$$\mathbf{X} = (X_0, X_1, \dots, X_{N-1})^T \in \mathbb{C}^N.$$

离散傅里叶变换可以表示为如下线性变换：

$$\mathbf{X} = F_N \mathbf{x}, \quad (8)$$

其中 $F_N \in \mathbb{C}^{N \times N}$ 为离散傅里叶变换矩阵

由此可见，DFT 本质上是一个复向量空间上的线性映射，其作用是将信号从标准基下的表示转换为一组由复指数函数张成的频率基下的表示。在图像压缩中，该过程对应于从空间域到频率域的变换。

2.4 多项式视角与基变换解释

若将向量 $\mathbf{x}$ 视为多项式

$$f(t) = \sum_{n=0}^{N-1} x_n t^n,$$

则 DFT 的结果满足

$$X_k = f(\omega_N^k), \quad k = 0, 1, \dots, N-1.$$

从线性代数角度看，该过程等价于一次坐标表示的改变，即从幂函数基下的系数表示，转换为复指数函数基下坐标的表示。这种基变换通常能够使信号的能量集中于少数低频分量，为图像压缩中的系数截断提供理论依据。

2.5 FFT 的矩阵分解思想

直接计算离散傅里叶变换需要进行一次 $N \times N$ 的矩阵-向量乘法，其时间复杂度为 $O(N^2)$ 。FFT 的核心思想在于，DFT 矩阵具有高度结构化的形式，可以利用分治的思想

通过置换矩阵与分块矩阵分解为多个低维 DFT 矩阵的组合，将复杂度降到 $O(N \log N)$ 。进一步还可以使用蝶形运算、位逆序置换等技巧加速运算。有关实现细节可参见 OI Wiki [1]。

这一过程本质上是将一个高维线性算子分解为若干低维线性算子的复合，体现了线性代数中通过矩阵分解与基重排来降低计算复杂度的基本思想。

2.6 FFT 的矩阵分解与分治解释

离散傅里叶变换可以表示为矩阵形式

$$\mathbf{X} = F_N \mathbf{x},$$

其中 F_N 为离散傅里叶变换矩阵。当 N 为 2 的幂时（事实上当 N 不为 2 的幂，我们可以通过补零的方式构造为 2 的幂）， F_N 具有良好的递归结构。

通过对输入向量进行适当的重排（对应于置换矩阵）， F_N 可以分解为如下形式：

$$F_N = \begin{pmatrix} I & D \\ I & -D \end{pmatrix} \begin{pmatrix} F_{N/2} & 0 \\ 0 & F_{N/2} \end{pmatrix} P, \quad (9)$$

其中 D 为由单位复根构成的对角矩阵， $F_{N/2}$ 为低维离散傅里叶变换矩阵， P 为置换矩阵，将原向量的偶数位和奇数位分离。具体地，若原向量为 $(x_0, x_1, x_2, \dots, x_{N-1})^T$ ，则置换后变为 $(x_0, x_2, x_4, \dots, x_{N-2}, x_1, x_3, x_5, \dots, x_{N-1})^T$

该分解表明，FFT 的分治过程在本质上是对离散傅里叶变换矩阵的递归分块分解。通过将一个高维线性算子表示为多个低维线性算子与简单矩阵的乘积，FFT 显著降低了计算复杂度。

2.7 蝶形运算的线性代数意义与实现优化

在 FFT 的分治合并阶段，已知偶、奇子序列在频域中的取值 $G(\omega_{n/2}^k)$ 与 $H(\omega_{n/2}^k)$ ，则原序列在对应频点处满足

$$\begin{pmatrix} f(\omega_n^k) \\ f(\omega_n^{k+n/2}) \end{pmatrix} = \begin{pmatrix} 1 & \omega_n^k \\ 1 & -\omega_n^k \end{pmatrix} \begin{pmatrix} G(\omega_{n/2}^k) \\ H(\omega_{n/2}^k) \end{pmatrix}. \quad (10)$$

从线性代数角度看，该合并过程本质上是在二维子空间上的一次线性变换，即所谓的“蝶形运算”。整个 FFT 过程可以理解为在不同二维子空间上反复施加此类局部线性算子，从而完成高维离散傅里叶变换。

在算法实现中，蝶形运算的优化并不体现在改变上述数学形式，而体现在数据布局与存储方式上。通过位逆序置换，使得 $G(\omega_{n/2}^k)$ 与 $H(\omega_{n/2}^k)$ 在数组中恰好位于相隔 $n/2$ 的两个位置，因此对应的两个输出也可直接覆写回原位置而无需额外数组。对不同段长反复执行这一原地合并操作，即可形成 FFT 的高效迭代实现。

2.8 二维离散傅里叶变换 (2D-DFT) 与可分离性

前面的讨论主要集中于一维离散傅里叶变换，其对象可以理解为一维离散信号（如时间序列或图像的一行像素）。然而，在图像压缩问题中，图像本质上是定义在二维离散网格上的函数，因此有必要将一维 DFT 的理论自然推广到二维情形。

设灰度图像表示为矩阵

$$A = (a_{x,y}) \in \mathbb{R}^{H \times W},$$

其中 $x = 0, 1, \dots, H-1$ 表示行索引， $y = 0, 1, \dots, W-1$ 表示列索引。二维离散傅里叶变换 (2D-DFT) 定义为

$$X(u, v) = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} a_{x,y} e^{-i2\pi(\frac{ux}{H} + \frac{vy}{W})}, \quad (11)$$

其中 (u, v) 分别表示垂直与水平方向的频率索引。

从线性代数角度看，二维 DFT 并不是一种全新的变换，而是一维 DFT 在两个正交方向上的自然叠加。记 F_H 与 F_W 分别为大小为 H 与 W 的一维离散傅里叶变换矩阵，则二维 DFT 可以写成紧凑的矩阵形式：

$$X = F_H A F_W^T. \quad (12)$$

该表示清晰地表明：二维傅里叶变换本质上是对图像矩阵先在行方向、再在列方向执行线性基变换。

这一结构直接导出了二维 FFT 的**可分离性 (separability)** 性质：二维 FFT 可以通过“先对每一行做一维 FFT，再对每一列做一维 FFT”来实现，而无需显式构造二维变换矩阵。这使得二维 FFT 的计算复杂度从直接矩阵乘法的 $O(H^2W^2)$ 降低至 $O(HW \log H + HW \log W)$ ，在实际图像处理中具有决定性意义。

在频域表示中，图像的低频分量通常集中在频谱的角落位置。通过对频谱进行适当的重排（如 `fftshift` 操作），可以将零频分量移动至频谱中心，从而更直观地观察能量分布。大量自然图像在二维频域中呈现出能量集中于低频区域的特性，这为后续基于频域系数截断的图像压缩方法提供了理论依据。

2.9 FFT 在图像压缩中的意义

在图像压缩问题中，FFT 及其相关变换主要体现了以下线性代数思想：首先，通过基变换将图像从像素基转换到频率基；其次，利用变换后系数的能量集中性，对幅值较小的高频分量进行舍弃；最后，依赖傅里叶变换的可逆性，实现压缩图像的近似重构。这些性质使 FFT 成为图像压缩中重要的理论工具。

3 PCA 数学原理

PCA (Principal Component Analysis, 主成分分析) 算法是线性代数理论在图像压缩领域的典型应用。尽管其在应用层面常被视为一种基于统计特性的特征提取技术, 但其数学内核植根于矩阵的低秩近似理论。本节将从统计学与代数学两个维度, 严谨阐述该算法的数学原理。

3.1 统计学视角: 协方差与最大方差理论

在数学建模中, 我们将图像的单颜色通道视为一个矩阵 $A \in \mathbb{R}^{H \times W}$, 其中 H 为图像高度, W 为宽度。为了利用主成分分析 (PCA) 提取图像的主要特征, 首先需要将图像的每一行视为 W 维空间中的一个数据样本。

设图像数据的行向量集合为 $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_H\}$, 其中 $\mathbf{a}_i \in \mathbb{R}^W$ 。为了消除原点偏移对二阶统计量的影响, 必须对数据进行中心化处理。计算样本均值向量 μ :

$$\mu = \frac{1}{H} \sum_{i=1}^H \mathbf{a}_i \quad (13)$$

中心化后的数据矩阵 X 定义为 $X = A - \mathbf{1}\mu$, 其中 $\mathbf{1}$ 为 H 维全 1 列向量。此时, 样本的协方差矩阵 C 可表示为:

$$C = \frac{1}{H-1} X^T X \quad (14)$$

协方差矩阵 C 是一个 $W \times W$ 的实对称矩阵。根据谱定理 (Spectral Theorem), 实对称矩阵必然可以被正交对角化, 即存在正交矩阵 P 和对角矩阵 Λ , 使得 $C = P\Lambda P^T$ 。

PCA 算法的目标是寻找一组正交基, 使得数据在该基上的投影方差最大。数学推导表明, 这组最优基恰好是协方差矩阵 C 的特征向量 (即矩阵 P 的列向量)。在图像信号中, 绝大多数能量 (方差) 集中在前 k 个最大特征值对应的方向上, 这为通过舍弃次要分量实现数据压缩提供了坚实的统计学基础。

3.2 代数视角: 奇异值分解 (SVD)

在实际的数值计算中, 显式构建协方差矩阵 $X^T X$ 不仅计算复杂度高达 $O(W^2 H)$, 且极易引入浮点数截断误差, 导致数值不稳定。因此, 现代图像压缩算法通常直接对中心化矩阵 X 进行奇异值分解 (Singular Value Decomposition, SVD)。

对于任意实矩阵 $X \in \mathbb{R}^{H \times W}$, 存在分解:

$$X = U\Sigma V^T \quad (15)$$

其中:

- $U \in \mathbb{R}^{H \times H}$ 是左奇异向量矩阵, 其列向量构成了行空间的正交基;
- $\Sigma \in \mathbb{R}^{H \times W}$ 是对角矩阵, 其对角元素 σ_i 为奇异值, 且满足 $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$;

- $V \in \mathbb{R}^{W \times W}$ 是右奇异向量矩阵，其列向量构成了定义域的正交基。

SVD 与 PCA 的内在联系可以通过以下推导揭示：

$$C \propto X^T X = (V \Sigma^T U^T)(U \Sigma V^T) = V(\Sigma^T \Sigma)V^T = V \Sigma^2 V^T \quad (16)$$

由此可见，SVD 分解得到的右奇异向量矩阵 V 恰好是协方差矩阵的特征向量矩阵，而奇异值 σ_i 与特征值 λ_i 满足关系 $\lambda_i \propto \sigma_i^2$ 。因此，SVD 提供了一种数值上更稳定、计算上更直接的方法来求解主成分。

3.3 最优低秩近似与 Eckart-Young-Mirsky 定理

PCA 压缩的核心步骤是矩阵截断（Truncation）。我们仅保留前 k 个最大的奇异值及其对应的奇异向量，构造近似矩阵 X_k ：

$$X_k = U_k \Sigma_k V_k^T \quad (17)$$

其中 U_k 为 U 的前 k 列， Σ_k 为前 k 个奇异值构成的对角阵， V_k^T 为 V^T 的前 k 行。

根据 **Eckart-Young-Mirsky 定理**，在所有秩为 k 的矩阵集合中， X_k 是原矩阵 X 在弗罗贝尼乌斯范数（Frobenius Norm）意义下的全局最优近似：

$$\min_{\text{rank}(Y)=k} \|X - Y\|_F = \|X - X_k\|_F = \sqrt{\sum_{i=k+1}^{\min(H,W)} \sigma_i^2} \quad (18)$$

该定理从数学上严格保证了，在给定的存储预算（即秩 k ）下，截断 SVD 能够保留原始图像最多的能量信息，是理论上的最优线性压缩方案。

4 FFT 图像压缩实验分析

4.1 算法实现流程

为了验证快速傅里叶变换在图像压缩中的实际效果，本文基于二维 FFT 设计并实现了一种频域截断型图像压缩算法。该方法与第 2 节中 FFT 的矩阵分解与基变换解释一一对应，其核心思想是：在频率基下保留能量集中的主要分量，舍弃幅值较小的高频系数。

具体流程如下：

1. **通道分离 (Channel Separation)**: 将彩色图像分解为 R、G、B 三个通道，分别处理。
2. **二维 FFT 变换**: 对每个通道矩阵 A 执行二维离散傅里叶变换

$$\hat{A} = F_H A F_W^T,$$

其中 F_H, F_W 为行、列方向的 DFT 矩阵。

3. **频谱中心化**: 对频谱执行零频移位 (fftshift), 使低频分量集中于中心区域。
4. **频域截断**: 按照频域系数模值大小排序, 仅保留前 k 个最大系数, 其余置零。
5. **逆变换重建**: 对截断后的频谱执行逆 FFT, 取实部作为重建图像。

4.2 实验设置

实验采用 Kodak Lossless True Color Image Suite。选取纹理复杂的 Image 1 与结构相对平滑的 Image 10 作为代表样本, 用于观察 FFT 压缩在不同图像内容下的表现。

设频域保留比例为

$$r \in \{1\%, 2\%, 5\%, 10\%\},$$

即仅保留 $r \times H \times W$ 个最大幅值的频域系数, 其余系数置零。

评价指标采用 PSNR、SSIM 以及压缩率 CR:

- **PSNR (峰值信噪比)**: 用于衡量重建图像与原图之间的像素级误差, 数值越大表示失真越小。
- **SSIM (结构相似性)**: 从亮度、对比度与结构信息三个方面评价图像相似度, 取值范围为 $[0, 1]$ 。
- **CR (压缩率)**: 定义为原始图像字节数与压缩载荷 (payload) 字节数之比。其中, raw 图像按 RGB 的 uint8 像素计; payload 指算法为重建图像而实际保存的参数表示 (本节 FFT 实验中为频域稀疏表示, 并以 npz 文件字节数计入其实际大小)。

4.3 实验结果与分析

表 1 汇总了不同保留比例 r 下的 FFT 压缩性能数据 (Image 1 与 Image 10)。实验结果表明, FFT 压缩对不同图像内容的敏感性较高: 平滑占主导的图像 (如 Image 10) 频谱能量集中于低频, 在较小保留比例下即可取得较高的 PSNR/SSIM; 纹理复杂的图像 (如 Image 1) 高频占比更大, 截断后细节损失更快显现。总体趋势显示, 随着保留比例 r 增大, PSNR 与 SSIM 单调上升, 而压缩率随之下降。图 1 给出了 Image 1 在不同 r 下的重建示意图, 可直观看到保留比例增大时网格纹理与边缘细节逐步恢复。

4.4 线性代数视角下的 FFT 压缩总结

FFT 图像压缩本质上是一次酉线性变换下的稀疏近似过程。通过将图像从像素基转换到频率基, 并在新基下执行系数截断, 实现了信息维度的有效缩减, 其最优性依赖于图像频谱的结构特征。

表 1: 不同保留比例 r 下的 FFT 图像压缩性能数据 (数据来源: 实验结果)					
样本 ID	Ratio (r)	MSE	PSNR (dB)	SSIM	CR (理论)
Image 1	1%	381.14	22.32	0.4681	13.23
	2%	295.18	23.43	0.5515	6.56
	5%	200.02	25.12	0.6634	2.49
	10%	133.38	26.88	0.7584	1.14
Image 10	1%	155.63	26.21	0.6613	13.38
	2%	115.63	27.50	0.7063	6.49
	5%	70.00	29.68	0.7790	2.53
	10%	41.41	31.96	0.8439	1.13




图 1: FFT 频谱能量分布与不同保留比例 r 下的重建示意 (Image 1)。上排为灰度频谱及 Top- k 掩膜叠加示意, 下排为对应的重建结果。

5 PCA 图像压缩实验

5.1 算法实现流程

为了验证上述理论的有效性，本文基于 Python 设计并实现了 PCA 图像压缩算法。算法流程严格遵循数学推导，针对 RGB 彩色图像的三个通道分别并行处理，具体步骤如下：

1. **通道分离 (Channel Separation)**: 将输入的三维图像张量 $I \in \mathbb{R}^{H \times W \times 3}$ 分解为 R、G、B 三个独立的二维矩阵。
2. **中心化预处理 (Centering)**: 对每个通道矩阵计算行均值向量，并执行减均值操作。这一步至关重要，它确保了数据分布中心位于零点，从而使 SVD 分解能够正确反映数据的方差结构。
3. **截断编码 (Truncated Encoding)**: 利用 SVD 算法分解各通道矩阵，并仅保留前 k 个奇异分量 (U_k, Σ_k, V_k) 以及均值向量作为压缩载荷 (Payload)。
4. **逆向重建 (Reconstruction)**: 解码端通过矩阵乘法 $\hat{X} = U_k \Sigma_k V_k^T$ 恢复近似数据，加上均值向量后，将数值截断至 $[0, 255]$ 区间并合并通道，生成最终的重建图像。

5.2 实验设置

实验设置与 FFT 部分保持一致，采用 Kodak Lossless True Color Image Suite，并选取 ‘kodim01’ 与 ‘kodim10’ 作为代表样本。主成分保留数设为 $k \in \{5, 10, 20, 40, 80\}$ ；评价指标为 PSNR、SSIM 与压缩率 CR，其中 CR 口径为 raw 图像字节数 (RGB uint8) 除以 payload 字节数，payload 由 (U_k, Σ_k, V_k) 及均值向量构成，统一以 float32 存储。

5.3 结果与讨论

为了深入分析算法在不同纹理特征下的表现，我们选取了纹理细节丰富的样本 (Image 1) 和结构相对简单的样本 (Image 10) 作为典型代表。详细实验数据如表 2 所示。图 2 给出了 Image 1 在不同保留秩 k 下的重建示意图，可直观看到随着 k 增大，纹理细节与边缘结构逐步恢复。

5.3.1 质量与秩的权衡分析

实验数据清晰地展示了压缩质量与秩 k 之间的正相关关系：

- **低秩区间 ($k = 5$)**: 此时压缩率极高 (CR > 13)，但 SSIM 较低 (Image 1 仅为 0.429)。图像丢失了大量高频纹理细节，仅保留了大致的颜色分布和低频轮廓，视觉体验较差。

表 2: 不同保留秩 k 下的图像压缩性能数据 (数据来源: 实验结果)

样本 ID	Rank (k)	MSE	PSNR (dB)	SSIM	CR (理论)
Image 1	5	495.72	21.18	0.429	13.70
	10	379.83	22.33	0.509	7.24
	20	282.66	23.62	0.593	3.73
	40	195.52	25.22	0.687	1.89
	80	116.29	27.48	0.789	0.95
Image 10	5	348.65	22.71	0.630	14.21
	10	225.15	24.61	0.663	7.38
	20	145.48	26.50	0.709	3.76
	40	84.70	28.85	0.779	1.90
	80	43.05	31.79	0.853	0.95



(a) $k = 5$



(b) $k = 10$



(c) $k = 20$



(d) $k = 40$



(e) $k = 80$

图 2: PCA 在不同保留秩 k 下的重建图像示意 (Image 1)。

- **中秩区间** ($k = 20 \sim 40$): 这是性能平衡的最优区间。PSNR 提升至 25dB 以上, SSIM 接近 0.7-0.8。算法在保持 2-4 倍压缩率的同时, 成功恢复了图像的主要结构信息, 达到了较好的视觉可用性。
- **高秩区间** ($k = 80$): 图像质量进一步提升 (PSNR > 27dB), 细节还原度极高, 但存储代价显著增加。

5.3.2 存储精度与“负压缩”现象的工程分析

通过深入分析实验数据, 我们发现了一个值得注意的工程现象: 当 $k = 80$ 时, 理论压缩率 CR 降至 0.95, 出现了“负压缩”(即压缩后的文件反而比原图大)。这一现象的根本原因在于数据存储类型的差异。原始图像像素使用 8 位无符号整数 (uint8, 1 字节/像素) 存储; 而 PCA 算法分解出的奇异向量矩阵 (U 和 V) 是连续实数, 通常需要 32 位浮点数 (float32, 4 字节/数值) 以维持运算精度。虽然 SVD 大幅减少了数据的“维度数量”(从 $H \times W$ 降维到 k 维子空间), 但单个数据的“位宽”增加了 4 倍。当保留的秩 k 较大时, 维度缩减带来的红利被浮点数存储的开销完全抵消。这表明, 基于 SVD 的压缩方法如果直接存储浮点矩阵, 并不适合高保真的无损级压缩。在实际工程应用中, 必须结合量化 (Quantization) 技术将浮点数降级 (如转为 float16 或 uint8), 才能在高 k 值下重获压缩优势。

5.3.3 图像内容的频谱敏感性

对比 Image 1 (复杂纹理) 和 Image 10 (简单结构) 的数据可以发现: 在相同的 $k = 40$ 下, Image 10 的 PSNR (28.85 dB) 显著优于 Image 1 (25.22 dB)。这验证了 PCA 算法对图像内容的频谱分布具有高度敏感性。Image 10 包含更多平滑区域, 其能量在频域上更集中于少数几个最大的奇异值 (奇异值衰减速度更快), 因此该算法能以更低的信息代价 (更小的 k) 还原更多的图像信息。这一特性也体现了 SVD 作为一种“自适应基变换”, 相较于固定基变换 (如 FFT/DCT) 更能捕捉数据的内在统计结构。

6 结论

本文以线性代数视角系统分析了 FFT 与基于 PCA 的图像压缩方法。理论上, FFT 提供了高效的矩阵分解与基变换框架, 适用于频域能量集中的压缩策略; PCA 则通过截断奇异值实现最优的低秩近似 (由 Eckart-Young-Mirsky 定理保证)。

实验表明: 对于 FFT 频域截断方法, 保留比例 r 增大时重建质量 (PSNR、SSIM) 单调提升, 但压缩率随之下降; 且图像内容对效果影响显著, 平滑区域占主导的样本在较小 r 下即可获得更高的 PSNR/SSIM, 而纹理复杂的样本更依赖较大的 r 才能保留细节。对于 PCA (截断 SVD) 方法, 保留奇异值个数 k 是决定重建质量与压缩率权衡的关键参数, 且同样受图像纹理复杂度影响; 此外, 浮点存储精度在高 k 时可能导致“负压缩”, 因此在工程实践中需配合合适的量化与编码策略以实现真实的存储收益。

当然，我们的算法与主流压缩算法如 JPEG、PNG 等存在差异，它们通常采用“变换——量化——熵编码”的完整流程，而本文主要关注线性表示与变换层面。不过，通过本次实验，我们清晰地展示了线性代数在图像压缩中的核心作用，为理解更复杂的压缩算法奠定了坚实的理论基础。

参考文献

- [1] OI Wiki, “快速傅里叶变换”, <https://oi-wiki.org/math/fft/>, 访问日期: 2026-01-01.